

## 6. zadatak - ANFIS

Marin Hrkec

18. prosinca 2020.

U sklopu ovog zadatka potrebno je izraditi neuro-fuzzy sustav ANFIS koji koristi Takagi-Sugeno-Kang (TSK) zaključivanje. Kod TSK zaključivanja, konsekvens je obična funkcija ulaznih varijabli. Sustav ima dva ulaza i jedan izlaz. Time se definira preslikavanje  $\mathbb{R}^2 \mapsto \mathbb{R}$ . Skup primjera za učenje je:  $\{((x_1, y_1), z_1), \dots, ((x_N, y_N), z_N))\}$ , a veličina skupa za učenje je  $N$ . Neuro-fuzzy sustav je definiran s  $m$  pravila  $R$ :

$R_1$ : Ako  $x$  je  $A_1$  i  $y$  je  $B_1$  onda  $f = p_1x + q_1y + r_1$

$R_2$ : Ako  $x$  je  $A_2$  i  $y$  je  $B_2$  onda  $f = p_2x + q_2y + r_2$

...

$R_m$ : Ako  $x$  je  $A_m$  i  $y$  je  $B_m$  onda  $f = p_mx + q_my + r_m$

Pri tome su  $A_i$  i  $B_i$  neizraziti skupovi. Neka su  $a_i$  i  $b_i$  parametri neizrazitog skupa  $A_i$ , a  $c_i$  i  $d_i$  parametri skupa  $B_i$ . Funkcije pripadnosti neizrazitih skupova  $A_i$  i  $B_i$  su modelirane sigmoidalnim funkcijama:

$$\begin{aligned} A_i(x) \equiv \mu_{A_i}(x) &= \frac{1}{1 + e^{b_i(x-a_i)}} \\ B_i(x) \equiv \mu_{B_i}(x) &= \frac{1}{1 + e^{d_i(x-c_i)}} \end{aligned} \quad [0.1]$$

Operator  $I$  (tj. t-norma) u antecedentu se modelira umnoškom. Za svako neizrazito pravilo  $R_i$  potrebno je odrediti pravila učenja koja ažuriraju 7 parametara:  $a_i$ ,  $b_i$ ,  $c_i$ ,  $d_i$ ,  $p_i$ ,  $q_i$  i  $r_i$ .

### Zadatak 1

Potrebno je izvesti postupak učenja koji se temelji na gradijentnom spustu prikladan za ovakvu mrežu. Uvode se pomoćne oznake:

$$\begin{aligned} \alpha_i &= A_i(x) \\ \beta_i &= B_i(y) \end{aligned} \quad [1.1]$$

Tada je jakost antecedenta:

$$\pi_i = t - \text{norma}(\alpha_i, \beta_i) = \alpha_i \cdot \beta_i. \quad [1.2]$$

Izlaz sustava je:

$$o_k = \frac{\sum_{i=1}^m \pi_i f_i}{\sum_{i=1}^m \pi_i} \quad [1.3]$$

Definira se funkcija pogreške za taj uzorak:

$$E_k = \frac{1}{2}(z_k - o_k)^2 \quad [1.4]$$

Za ažuriranje proizvoljnog parametra  $\psi$  minimizacijom funkcije pogreške uporabom gradijentnog spusta koristi se izraz:

$$\psi(t+1) = \psi(t) - \eta \cdot \frac{\partial E_k}{\partial \psi} \quad [1.5]$$

Pri tome je  $\eta$  stopa učenja. Potrebno je utvrditi parcijalne derivacije funkcije  $E_k$  po svim parametrima. Računa se redom:

$$\frac{\partial E_k}{\partial f_i} = \frac{\partial E_k}{\partial o_k} \cdot \frac{\partial o_k}{\partial f_i} \quad [1.6]$$

$$\begin{aligned} \frac{\partial E_k}{\partial o_k} &= -(z_k - o_k) \\ \frac{\partial o_k}{\partial f_i} &= \frac{\pi_i}{\sum_{j=1}^m \pi_j} \\ \frac{\partial E_k}{\partial f_i} &= -(z_k - o_k) \cdot \frac{\pi_i}{\sum_{j=1}^m \pi_j} \end{aligned} \quad [1.7]$$

Gradijent u odnosu na parametre  $p_i$ ,  $q_i$  i  $r_i$ :

$$\frac{\partial E_k}{\partial p_i} = \frac{\partial E_k}{\partial f_i} \cdot \frac{\partial f_i}{\partial p_i} \quad [1.8]$$

$$\begin{aligned} \frac{\partial f_i}{\partial p_i} &= x \\ \frac{\partial E_k}{\partial p_i} &= -(z_k - o_k) \cdot \frac{\pi_i}{\sum_{j=1}^m \pi_j} \cdot x \end{aligned} \quad [1.9]$$

$$\frac{\partial E_k}{\partial q_i} = \frac{\partial E_k}{\partial f_i} \cdot \frac{\partial f_i}{\partial q_i} \quad [1.10]$$

$$\begin{aligned} \frac{\partial f_i}{\partial q_i} &= y \\ \frac{\partial E_k}{\partial q_i} &= -(z_k - o_k) \cdot \frac{\pi_i}{\sum_{j=1}^m \pi_j} \cdot y \end{aligned} \quad [1.11]$$

$$\frac{\partial E_k}{\partial r_i} = \frac{\partial E_k}{\partial f_i} \cdot \frac{\partial f_i}{\partial r_i} \quad [1.12]$$

$$\begin{aligned} \frac{\partial f_i}{\partial r_i} &= 1 \\ \frac{\partial E_k}{\partial r_i} &= -(z_k - o_k) \cdot \frac{\pi_i}{\sum_{j=1}^m \pi_j} \end{aligned} \quad [1.13]$$

Gradijent u odnosu na parametre  $a_i$ ,  $b_i$ ,  $c_i$  i  $d_i$ :

$$\frac{\partial E_k}{\partial a_i} = \frac{\partial E_k}{\partial o_k} \cdot \frac{\partial o_k}{\partial \pi_i} \cdot \frac{\partial \pi_i}{\partial \alpha_i} \cdot \frac{\partial \alpha_i}{\partial a_i} \quad [1.14]$$

$$\frac{\partial E_k}{\partial b_i} = \frac{\partial E_k}{\partial o_k} \cdot \frac{\partial o_k}{\partial \pi_i} \cdot \frac{\partial \pi_i}{\partial \alpha_i} \cdot \frac{\partial \alpha_i}{\partial b_i} \quad [1.15]$$

$$\begin{aligned} \frac{\partial o_k}{\partial \pi_i} &= \frac{f_i \cdot \sum_{j=1}^m \pi_j - \sum_{j=1}^m f_j \pi_j}{\left(\sum_{j=1}^m \pi_j\right)^2} = \frac{\sum_{j=1, j \neq i}^m (f_i - f_j) \cdot \pi_j}{\left(\sum_{j=1}^m \pi_j\right)^2} \\ \frac{\partial \pi_i}{\partial \alpha_i} &= \beta_i \\ \frac{\partial \alpha_i}{\partial a_i} &= b_i \cdot \alpha_i \cdot (1 - \alpha_i) \\ \frac{\partial \alpha_i}{\partial b_i} &= -(x - a_i) \cdot \alpha_i \cdot (1 - \alpha_i) \end{aligned} \quad [1.16]$$

$$\frac{\partial E_k}{\partial a_i} = -(z_k - o_k) \cdot \frac{\sum_{j=1, j \neq i}^m (f_i - f_j) \cdot \pi_j}{\left(\sum_{j=1}^m \pi_j\right)^2} \cdot \beta_i \cdot b_i \cdot \alpha_i \cdot (1 - \alpha_i) \quad [1.17]$$

$$\frac{\partial E_k}{\partial a_i} = (z_k - o_k) \cdot \frac{\sum_{j=1, j \neq i}^m (f_i - f_j) \cdot \pi_j}{\left(\sum_{j=1}^m \pi_j\right)^2} \cdot \beta_i \cdot (x - a_i) \cdot \alpha_i \cdot (1 - \alpha_i) \quad [1.18]$$

$$\frac{\partial E_k}{\partial c_i} = \frac{\partial E_k}{\partial o_k} \cdot \frac{\partial o_k}{\partial \pi_i} \cdot \frac{\partial \pi_i}{\partial \beta_i} \cdot \frac{\partial \beta_i}{\partial c_i} \quad [1.19]$$

$$\frac{\partial E_k}{\partial d_i} = \frac{\partial E_k}{\partial o_k} \cdot \frac{\partial o_k}{\partial \pi_i} \cdot \frac{\partial \pi_i}{\partial \beta_i} \cdot \frac{\partial \beta_i}{\partial d_i} \quad [1.20]$$

$$\begin{aligned} \frac{\partial \pi_i}{\partial \beta_i} &= \alpha_i \\ \frac{\partial \beta_i}{\partial c_i} &= d_i \cdot \beta_i \cdot (1 - \beta_i) \\ \frac{\partial \beta_i}{\partial d_i} &= -(y - c_i) \cdot \beta_i \cdot (1 - \beta_i) \end{aligned} \quad [1.21]$$

Nakon izvedenih svih parcijalnih derivacija, mogu se zapisati izrazi za ažuriranje svih parametara:

$$p_i(t+1) = p_i(t) + \eta(z_k - o_k) \cdot \frac{\pi_i}{\sum_{j=1}^m \pi_j} \cdot x \quad [1.22]$$

$$q_i(t+1) = q_i(t) + \eta(z_k - o_k) \cdot \frac{\pi_i}{\sum_{j=1}^m \pi_j} \cdot y \quad [1.23]$$

$$r_i(t+1) = r_i(t) + \eta(z_k - o_k) \cdot \frac{\pi_i}{\sum_{j=1}^m \pi_j} \quad [1.24]$$

$$a_i(t+1) = a_i(t) + \eta(z_k - o_k) \cdot \frac{\sum_{j=1, j \neq i}^m (f_i - f_j) \cdot \pi_j}{\left(\sum_{j=1}^m \pi_j\right)^2} \cdot \beta_i \cdot b_i \cdot \alpha_i \cdot (1 - \alpha_i) \quad [1.25]$$

$$b_i(t+1) = b_i(t) - \eta(z_k - o_k) \cdot \frac{\sum_{j=1, j \neq i}^m (f_i - f_j) \cdot \pi_j}{\left(\sum_{j=1}^m \pi_j\right)^2} \cdot \beta_i \cdot (x - a_i) \cdot \alpha_i \cdot (1 - \alpha_i) \quad [1.26]$$

$$c_i(t+1) = c_i(t) + \eta(z_k - o_k) \cdot \frac{\sum_{j=1, j \neq i}^m (f_i - f_j) \cdot \pi_j}{\left(\sum_{j=1}^m \pi_j\right)^2} \cdot \alpha_i \cdot d_i \cdot \beta_i \cdot (1 - \beta_i) \quad [1.27]$$


$$d_i(t+1) = d_i(t) - \eta(z_k - o_k) \cdot \frac{\sum_{j=1, j \neq i}^m (f_i - f_j) \cdot \pi_j}{\left(\sum_{j=1}^m \pi_j\right)^2} \cdot \alpha_i \cdot (y - c_i) \cdot \beta_i \cdot (1 - \beta_i) \quad [1.28]$$

## Zadatak 2

Potrebno je generirati skup podataka za učenje. Zadana je funkcija:

$$f(x, y) = ((x - 1)^2 + (y + 2)^2 - 5xy + 3) \cdot \cos^2\left(\frac{x}{5}\right) \quad [2.1]$$


koja je definira nad domenom  $x \in [-4, 4]$ ,  $y \in [-4, 4]$ . Skup podataka za učenje čine uzorci funkcije po svim cijelim brojevima iz domene.



Slika 1: Graf zadane funkcije


### Zadatak 3

Na temelju primjera za učenje potrebno je provesti učenje ANFIS sustava pomoću obje inačice algoritma učenja. Na slici 2 je prikazan graf funkcije koju je naučio ANFIS nad zadanom domenom. Naučeni sustav sadrži 10 pravila zaključivanja.




Slika 2: Graf funkcije koju je naučio ANFIS

Funkcija pogreške uzorka  $\delta(x, y)$  je definirana kao razlika između vrijednosti koji sustav ANFIS daje na izlazu za točku  $(x, y)$  i stvarne vrijednosti koju zadana funkcija poprima u točki  $(x, y)$ :  $\delta(x, y) = o(x, y) - z(x, y)$ . Kako se kreću odstupanja naučene funkcije i uzoraka za učenje prikazano je na slici 3.




Slika 3: Odstupanja naučene funkcije i uzoraka za učenje


Na slikama 4, 5 i 6 su prikazani izgledi naučenih funkcija pripadnosti.




(a) Pravilo 1 - linearna funkcija




(b) Pravilo 1 - funkcija pripadnosti




(c) Pravilo 2 - linearna funkcija




(d) Pravilo 2 - funkcija pripadnosti




(e) Pravilo 3 - linearna funkcija



(f) Pravilo 3 - funkcija pripadnosti




(g) Pravilo 4 - linearna funkcija




(h) Pravilo 4 - funkcija pripadnosti


Slika 4: Naučena pravila 1 - 4




(a) Pravilo 5 - linearna funkcija




(b) Pravilo 5 - funkcija pripadnosti




(c) Pravilo 6 - linearna funkcija




(d) Pravilo 6 - funkcija pripadnosti




(e) Pravilo 7 - linearna funkcija



(f) Pravilo 7 - funkcija pripadnosti




(g) Pravilo 8 - linearna funkcija




(h) Pravilo 8 - funkcija pripadnosti


Slika 5: Naučena pravila 5 - 8




(a) Pravilo 9 - linearna funkcija



(b) Pravilo 9 - funkcija pripadnosti



(c) Pravilo 10 - linearna funkcija




(d) Pravilo 10 - funkcija pripadnosti

Slika 6: Naučena pravila 9 i 10


## Zadatak 4

Za neuro-fuzzy sustav s 10 pravila ponavlja se postupak učenja s obje inačice algoritma i nakon učenja se u datoteku pohrane pogreške koje je sustav radio nakon svake epohe učenja. Na slici 7 je prikazan graf kretanja pogreške ovisno o broju epohe.






(a) Varijanta koja se temelji na izračunu pravog gradijenta




(b) Stohastička varijanta


Slika 7: Graf kretanja pogreške ovisno o epohi



(a) Vrlo mala stopa učenja



(b) Prikladna stopa učenja




(c) Vrlo velika stopa učenja


Slika 8: Varijanta koja se temelji na izračunu pravog gradijenta

## Zadatak 5


Za ANFIS sustav s 10 pravila za obje inačice algoritma ponavlja se postupak učenja za tri rubne vrijednosti stope učenja (vrlo mala, prikladna i vrlo velika). Na slici 8 je prikazan graf kretanja srednje kvadratne pogreške ovisno o broju epohe za različite vrijednosti stope učenja za varijantu koja se temelji na izračunu pravog gradijenta, a na slici 9 za stohastičku varijantu.



(a) Vrlo mala stopa učenja



(b) Prikladna stopa učenja



(c) Vrlo velika stopa učenja

Slika 9: Stohastička varijanta